

Relatório Técnico — Atividade 1 (AV1) de Sistemas Operacionais

Processos, Threads, Escalonamento e Inferência Local com Ollama

Discente: Leticia Cavalcanti **Modalidade:** Individual **Trilha:** A — Chat local: Ollama + Open WebUI **Modelo:** Llama-3.2-3B-Instruct (GGUF, Q4_K_M) **Repositório:** (preencher com a URL do GitHub, ex.:

https://github.com//SO_UFS_2026_2_Cavalcanti_Leticia) **Vídeo da atividade:** (preencher — ver VIDEO.md) **Data:** 2026-09-15

1. Introdução e problema

Aplicações de IA generativa executadas localmente mobilizam processos, threads, memória, armazenamento, comunicação em rede, arquivos, logs, bibliotecas, runtimes e mecanismos de proteção do sistema operacional. Este relatório documenta a instalação, execução e análise experimental de um sistema local de IA generativa baseado em **Ollama** com a interface **Open WebUI** (Trilha A), relacionando conceitos de Sistemas Operacionais — processos, threads, chamadas de sistema e escalonamento — ao comportamento observado.

Pergunta norteadora: como a camada de aplicação, o modelo de linguagem, a quantidade de parâmetros, a quantização e a configuração de execução afetam processos, threads, uso de CPU, memória, armazenamento e responsividade de um sistema local de IA generativa?

2. Trilha e modelo

- **Trilha escolhida:** A — Ollama + Open WebUI.
- **Modelo:** Llama-3.2-3B-Instruct, família Llama 3.2, variante Instruct, ~3,21 bilhões de parâmetros, formato GGUF, quantização Q4_K_M, licença Llama 3.2 Community License.
- **Model card:** <https://huggingface.co/meta-llama/Llama-3.2-3B-Instruct>
- **Justificativa:** modelo de porte reduzido (dentro do limite de 10B parâmetros), o que permite instalação e execução mais rápidas em ambiente local via Ollama. A quantização Q4_K_M reduz o consumo de memória e armazenamento sem comprometer significativamente a qualidade das respostas, facilitando a coleta de métricas de processos, threads, uso de CPU/memória e chamadas de sistema exigidas na Trilha A.
- **Nota de proveniência:** ver observação no [README.md](#) sobre a diferença entre o model card original (safetensors, gated) e o artefato GGUF Q4_K_M efetivamente executado (biblioteca oficial do Ollama, tag `llama3.2:3b`).

3. Ambiente experimental

Inventário completo em [data/ambiente inventario.txt](#), coletado com `scripts/00_inventario_ambiente.sh` em 2026-09-15.

- **Tipo de ambiente:** contêineres Docker (`ollama` e `open-webui`), executados sobre a VM Linux do Docker Desktop com backend **WSL2**, no host Windows 11.
- **Distribuição/versão Linux do container:** Ubuntu 24.04.4 LTS (Noble Numbat).
- **Kernel:** `6.6.87.2-microsoft-standard-WSL2` (x86_64).
- **CPU:** Intel(R) Core(TM) i5-10210U @ 1.60GHz, 4 CPUs alocadas ao Docker Desktop (2 núcleos físicos / 4 threads via Hyper-Threading), sem GPU (sem NVIDIA/ `nvidia-smi`) — execução 100% em CPU.
- **RAM:** 5,8 GiB alocados ao Docker Desktop (container `ollama` chegou a usar ~3,7 GiB durante os experimentos com `num_ctx=8192`).
- **Armazenamento:** 1007 GB no overlay do container, 34 GB usados, 922 GB disponíveis; modelo `llama3.2:3b` ocupou 2,0 GB.
- **Versão do Ollama:** 0.34.0. **Modelo carregado:** `llama3.2:3b` (GGUF, Q4_K_M).

Execução inicial: `docker compose up -d` baixou e extraiu as imagens (`ollama/ollama` ~3,56 GB comprimidos; `open-webui`) em ~6 minutos na primeira execução. O download do modelo (`ollama pull llama3.2:3b`, 2,0 GB) levou **2min20s**. Portas expostas: 11434 (API do Ollama) e 3000 (interface web do Open WebUI, mapeada para a porta interna 8080). Nenhum erro ou aviso relevante nos logs de inicialização dos dois containers.

4. Arquitetura

Ver diagrama e descrição em [README.md](#).

5. Processos, threads e chamadas de sistema

5.1 Processos e threads

Evidências completas em [data/ps_snapshots/](#), geradas por `scripts/02_processos_threads.sh`.

- **Em repouso:** único processo relevante é `ollama` (PID 1, `ollama serve`), estado `ssl`, **25 threads (NLWP)**, ~0,6% de memória do container.
- **Durante a inferência:** o Ollama cria um **processo filho** `llama-server` (PID 149, PPID 1), estado `RI` (rodando, multithread), com **9 threads próprias**, consumindo ~91,5% de CPU e ~14,9% de memória do container no momento da amostra. O processo pai `ollama` (PID 1) permanece com suas 25 threads originais, agora orquestrando a requisição.
- `ps -eLf` confirma a hierarquia: as 25 LWPs (light-weight processes) do PID 1 pertencem ao runtime do Ollama (servidor HTTP, gerenciador de modelos), enquanto o comando completo do processo filho revela os parâmetros de execução do `llama-server`: `--model /root/.ollama/models/blobs/sha256-...`, `-c 4096` (tamanho de contexto), `-np 1` (1 slot de processamento paralelo), `--flash-attn auto`, `-b 512 -ub 512` (tamanho de lote/ubatch).
- **Comparação repouso x inferência:** o número de processos do container passou de ~3 (repouso) para 5+ (inferência), e o processo `llama-server` sozinho concentrou ~91% de CPU do container durante a geração — evidenciando que o `ollama serve` atua como processo supervisor/API, e todo o trabalho pesado de inferência é delegado a um processo filho dedicado, criado sob demanda e encerrado após a requisição.
- Uso agregado por container (`docker stats`, amostra única) ao final da inferência: `ollama` 3,15 GiB / 5,79 GiB (54,4%), 36 PIDs; `open-webui` 853 MiB (14,4%), 31 PIDs — ver `data/ps_snapshots/05_docker_stats.txt`.

5.2 Chamadas de sistema

Resumo completo (`strace -f -c -p 1`, anexado ao container `ollama` durante uma requisição controlada) em [data/strace/strace-resumo.txt](#) — 6.644 chamadas capturadas, 434 delas retornando erro (majoritariamente `EAGAIN` esperado em sockets não bloqueantes). As quatro famílias mais relevantes:

- **Sincronização entre threads/escalonamento** (`futex`, `sched_yield`, `tgkill`): **72,8% do tempo total** de CPU em chamadas de sistema foi gasto em `futex` (2.355 chamadas) — o mecanismo do Linux para sincronizar as threads de inferência (produtor/consumidor de tokens, pool de threads do llama.cpp) sem busy-waiting. `sched_yield` (293 chamadas) mostra threads cedendo voluntariamente a CPU ao escalonador, comportamento típico de pools de threads paralelas competindo por poucos núcleos.
- **Rede** (`epoll_pwait`, `socket`, `accept4`, `connect`, `getsockopt` / `getsockname` / `getpeername`): 8,9% do tempo em `epoll_pwait` (1.207 chamadas) — o loop de eventos do servidor HTTP do Ollama monitorando a API local na porta 11434 e a conexão interna com o `llama-server`.
- **Arquivos/E-S** (`read`, `write`, `openat`, `pread64`, `close`, `newfstatat`, `getdents64`): leitura do arquivo de pesos GGUF e de logs — `read` (863 chamadas, 3,0% do tempo).
- **Memória** (`madvise`): 66 chamadas, usadas pelo alocador para sinalizar ao kernel o padrão de acesso às páginas que armazenam os pesos do modelo e o cache de contexto (KV-cache).
- **Temporização** (`nanosleep`): 12,9% do tempo, 1.481 chamadas — indicativo de espera ativa/polling controlado em partes do runtime.

Essas evidências confirmam, na prática, que a maior parte do "custo" de uma inferência não está em syscalls de I/O, e sim em **sincronização entre threads** (`futex`) — coerente com uma carga de trabalho fortemente paralela em CPU, disputando os 4 núcleos disponíveis.

6. Metodologia dos experimentos

Foram executadas 12 rodadas mensuráveis, cobrindo três configurações, pelo menos dois tamanhos de entrada (prompt curto e prompt longo) e pelo menos duas repetições por cenário, conforme `scripts/04_experimentos.py`:

- **Configuração 1 — execução padrão:** prompt curto x longo, 2 repetições cada (4 execuções), requisições sequenciais, `num_ctx` padrão.

- **Configuração 2 — concorrência controlada:** prompt longo, comparando 1 requisição por vez x 4 requisições simultâneas, 2 repetições cada (4 rounds; 1+4 requisições por round).
- **Configuração 3 — ajuste de execução local (contexto):** prompt longo, comparando `num_ctx=2048` x `num_ctx=8192`, 2 repetições cada (4 execuções).

Métricas coletadas por requisição (via campos da própria API do Ollama, ver [documentação oficial](#)): tempo total (`total_duration`), tempo de carregamento do modelo (`load_duration`), TTFT aproximado (`load_duration` + `prompt_eval_duration`), tokens/segundo (`eval_count` / `eval_duration`), além de uso de CPU/memória do container (`docker stats`) e número de threads (`ps -eo nlwp`) por round.

7. Resultados

Execuções realizadas em 2026-09-15, entre 16h46 e 17h27 (horário local), 12 rounds, 22 requisições individuais (18 concluídas com sucesso, 6 com timeout — ver Configuração 2). Dados brutos em `data/experimentos/resultados.csv` (por requisição) e `data/experimentos/resumo_rounds.csv` (por round); tabelas completas em `data/experimentos/tabelas_resumo.md`.

Tabela 1 — Resumo por configuração/cenário (médias por requisição concluída)

Configuração	Cenário	N	Tempo total médio (s)	TTFT médio (s)	Tokens/s médio	Erros
Config 1 — padrão	prompt curto	2	9,80	0,57	6,57	0
Config 1 — padrão	prompt longo	2	188,75	2,33	5,17	0
Config 2 — concorrência	1 requisição/vez	2	166,88	0,14	5,13	0
Config 2 — concorrência	4 requisições simultâneas	8 (2 OK, 6 timeout)	191,55 (só sucessos)	0,15	4,98 (só sucessos)	6
Config 3 — contexto	<code>num_ctx=2048</code>	2	192,20	5,89	5,04	0
Config 3 — contexto	<code>num_ctx=8192</code>	2	232,86	6,39	4,14	0

Tabela 2 — Uso de recursos por round (amostra pontual via `docker stats` + `ps -eo nlwp`)

Round	Configuração/Cenário	Concorrência alvo	Wall time (s)	CPU container (amostra)	Memória container
7	Config 2 — concorrência=4	4	300,03 (timeout)	55,15%	3,38 GiB
8	Config 2 — concorrência=4	4	300,02 (timeout)	74,76%	3,52 GiB
5–6	Config 2 — concorrência=1	1	127–207	0,12–0,45%	3,13–3,24 GiB
9–10	Config 3 — <code>num_ctx=2048</code>	1	188–196	0,00–0,40%	2,75–2,82 GiB
11–12	Config 3 — <code>num_ctx=8192</code>	1	216–249	0,46–0,76%	3,58–3,68 GiB

Gráfico principal — efeito da concorrência:





Gráfico — efeito do tamanho de contexto:

Config. 3 - Contexto: num_ctx=2048 vs 8192



8. Discussão

Concorrência (Configuração 2): com 1 requisição por vez, os tempos médios (127–207s) ficam na mesma ordem de grandeza da Configuração 1 com prompt longo. Ao disparar **4 requisições simultâneas** no host de 4 CPUs, **apenas 1 de cada 4 requisições completou dentro do timeout de 300s em cada round** (6 de 8 requisições — 75% — falharam por timeout). O uso de CPU do container saltou para 55–75% na amostra pontual (contra <1% nos cenários sequenciais), confirmando saturação de CPU: como não há GPU e o host tem apenas 4 núcleos lógicos, rodar 4 inferências `llama.cpp` em paralelo faz cada uma competir por fatias de CPU cada vez menores, em vez de ganhar paralelismo real — a vazão (tokens totais gerados por unidade de tempo) **piora drasticamente**, e a responsividade também piora (75% das requisições nem retornam a tempo). O custo observado nos dados de `strace` (72,8% do tempo em `futex`) é coerente com esse gargalo: threads gastam mais tempo se sincronizando e disputando CPU do que efetivamente calculando.

Contexto (Configuração 3): aumentar `num_ctx` de 2048 para 8192 elevou o tempo total médio de ~192s para ~233s (+21%) e o uso de memória do container de ~2,75–2,82 GiB para ~3,58–3,68 GiB (+30%), mesmo mantendo os mesmos prompt e número de tokens gerados. Além disso, a **primeira** requisição de cada novo valor de `num_ctx` teve `load_duration` não-nulo (6,67s e 6,36s, respectivamente) — evidência de que uma mudança no tamanho de contexto força o Ollama a **recarregar o modelo** com um KV-cache maior, custo que não aparece nas requisições subsequentes com o mesmo `num_ctx` (`load_duration=0,001–0,004s`).

Qualidade das respostas: todas as 18 requisições concluídas produziram respostas coerentes e não vazias (critério adotado: resposta com mais de 30 caracteres úteis, coluna `qualidade=OK` em `resultados.csv`); nenhuma resposta incompleta ou visivelmente incoerente foi observada nos casos que não sofreram timeout.

9. Relação com Sistemas Operacionais e IA generativa

O runtime do Ollama ilustra, na prática, conceitos centrais de Sistemas Operacionais: um processo principal que atende requisições via sockets TCP (chamadas `socket / accept / epoll`), um processo/thread "runner" responsável pela inferência (criado via `clone`, comunicando-se por memória mapeada e sincronizado com `futex`), escalonamento cooperativo das threads de inferência pelo CFS do kernel Linux, e uso de `mmap` para carregar o arquivo de pesos GGUF sem duplicar todo o conteúdo em memória residente. A execução em contêiner acrescenta uma camada de isolamento de namespaces e cgroups, que limita e contabiliza os recursos (CPU, memória) usados pelo processo Ollama, visível via `docker stats`.

10. Limitações

- Execução 100% em CPU (sem GPU disponível no host), o que restringe a comparação CPU/GPU prevista como uma das variações possíveis da Configuração 3.
- Ambiente virtualizado (Docker Desktop sobre WSL2) introduz uma camada adicional de virtualização em relação a uma instalação nativa Linux, podendo afetar levemente medições de tempo absoluto (embora não a análise qualitativa de processos/threads/syscalls).
- Amostra de 12 execuções é o mínimo exigido; variações de carga do host Windows durante os testes podem introduzir ruído nas medições de tempo.

11. Declaração de uso de IA

Ver [declaracao_uso_ia.md](#).

12. Conclusão

Os experimentos confirmam que, em um sistema local de IA generativa baseado em Ollama, o comportamento de processos, threads e uso de recursos depende fortemente de três fatores testados. **(1) Camada de aplicação e arquitetura:** a Trilha A evidenciou uma separação clara entre o processo supervisor (`ollama serve`, sempre ativo, 24–25 threads) e um processo de inferência criado sob demanda (`llama-server`, ~9 threads, responsável pelo consumo intenso de CPU), comunicando-se via API HTTP local. **(2) Concorrência:** em hardware limitado a 4 CPUs e sem GPU, aumentar a concorrência de 1 para 4 requisições simultâneas não trouxe ganho de vazão — pelo contrário, causou saturação de CPU e 75% de timeouts, um custo que só aparece sob carga real e não é visível em uma única requisição isolada. **(3) Configuração de execução (contexto):** um contexto maior (`num_ctx` 8192 vs 2048) aumentou tempo (~+21%) e memória (~+30%) de forma proporcional, além de exigir recarregamento do modelo ao ser alterado. Em conjunto, esses resultados respondem à pergunta norteadora: a responsividade e o uso de recursos de um sistema local de IA generativa são determinados menos pelo tamanho do modelo em si (fixo, 3B parâmetros neste estudo) e mais pela **configuração de execução** — concorrência e tamanho de contexto —, que interage diretamente com as capacidades de escalonamento e paralelismo do sistema operacional subjacente.

13. Respostas às questões de análise (Seção 9 do enunciado)

16. Por que a trilha escolhida é adequada à disciplina? A Trilha A expõe de forma direta processos e threads distintos (Ollama e Open WebUI), comunicação via API HTTP local (sockets), execução em contêiner (namespaces/cgroups) e persistência via volumes — cobrindo múltiplos tópicos centrais de Sistemas Operacionais em um cenário real de IA generativa.

17. Qual modelo foi selecionado, quais são seus parâmetros e por que foi escolhido? Ver Seção 2.

18. Como formato, quantização, contexto e tamanho afetaram armazenamento, RAM ou VRAM? O modelo em GGUF Q4_K_M ocupou **2,0 GB** em disco (`ollama list`). O tamanho do contexto (`num_ctx`) teve efeito direto e mensurável na RAM: subir de 2048 para 8192 tokens elevou o uso de memória do container de ~2,75–2,82 GiB para ~3,58–3,68 GiB (+30%), pois o KV-cache cresce proporcionalmente ao tamanho do contexto. Trocar `num_ctx` também obriga o Ollama a recarregar o modelo (custo adicional de ~6,3–6,7s de `load_duration` na primeira requisição após a troca). Sem GPU disponível, não houve uso de VRAM neste experimento.

19. Quais processos e threads foram observados na inicialização e na inferência? Ver Seção 5.1.

20. Quais chamadas de sistema foram relevantes para carga, leitura de dados, comunicação ou logs? Ver Seção 5.2.

21. O aumento de concorrência melhorou responsividade ou vazão? Quais custos surgiram? Não — piorou ambas. Com 4 requisições simultâneas em um host de 4 CPUs (sem GPU), 75% das requisições (6 de 8) não completaram dentro do timeout

de 300s; a única requisição concluída por round não foi mais rápida que o cenário sequencial. O custo dominante foi contenção de CPU (uso subiu para 55–75% na amostra, contra <1% em execução sequencial) e maior tempo gasto em sincronização de threads (`futex` , 72,8% do tempo de syscalls medido via `strace`). Ver Seção 8.

22. Houve competição por CPU, memória, armazenamento, GPU ou rede? Sim, principalmente por **CPU**: os 4 núcleos lógicos do host foram o gargalo evidente na Configuração 2 (concorrência=4). Houve também competição por **memória** de forma mais branda na Configuração 3, onde contextos maiores aumentaram o uso de RAM em ~30%. Não houve GPU disponível para competição, e o armazenamento (SSD/overlay Docker) não se mostrou gargalo nos testes realizados. Rede não foi um fator limitante, por se tratar de comunicação local (`localhost` /rede interna dos containers).

23. Como entradas ou contextos maiores afetaram desempenho e recursos? Prompts mais longos (Configuração 1: curto x longo) aumentaram o tempo total de ~9,8s para ~188,75s (a resposta também é proporcionalmente maior — de ~60 para ~900+ tokens gerados) e o TTFT de ~0,57s para ~2,33s. Contextos maiores (Configuração 3: `num_ctx` 2048 x 8192) aumentaram o tempo total médio em ~21% e o uso de memória em ~30%, além de introduzir um custo único de recarregamento do modelo ao trocar o tamanho de contexto. Ver Seção 8.

24. Como a arquitetura local contribui para privacidade, disponibilidade e controle de dados? Por rodar inteiramente em containers locais, sem chamadas a APIs externas, os dados de conversas e documentos não saem da máquina da discente; a aplicação também continua funcional offline (após o download do modelo), sem depender de disponibilidade de um provedor remoto.

25. Quais limitações ameaçam a validade dos resultados? Ver Seção 10.

26. Quais informações geradas por IA precisaram ser verificadas, corrigidas ou rejeitadas? Ver [declaracao uso ia.md](#).

14. Referências

- SILBERSCHATZ, Abraham; GALVIN, Peter B.; GAGNE, Greg. *Operating System Concepts*. 10. ed. Hoboken: Wiley, 2018.
- TANENBAUM, Andrew S.; BOS, Herbert. *Modern Operating Systems*. 5. ed. Boston: Pearson, 2023.
- KERRISK, Michael. *The Linux Programming Interface*. San Francisco: No Starch Press, 2010.
- LINUX MAN-PAGES PROJECT. `fork(2)`, `execve(2)`, `wait(2)`, `clone(2)`, `pthread(7)`, `sched(7)`. Disponível em: <https://man7.org/linux/man-pages/>.
- THE LINUX KERNEL DOCUMENTATION. *Scheduler documentation*. Disponível em: <https://docs.kernel.org/scheduler/>.
- OLLAMA. Repositório oficial e documentação da API. Disponível em: <https://github.com/ollama/ollama>.
- OPEN WEBUI. Repositório oficial. Disponível em: <https://github.com/open-webui/open-webui>.
- HUGGING FACE. Models. Disponível em: <https://huggingface.co/models>.
- NIST. *Artificial Intelligence Risk Management Framework: Generative Artificial Intelligence Profile*. NIST AI 600-1, 2024. Disponível em: <https://doi.org/10.6028/NIST.AI.600-1>.

URL do vídeo: (*preencher — ver VIDEO.md*)